데이터 분석 포트폴리오 v0.1

구매에서 지급까지 , 어디서 시간이 걸리나

도료 제조사의 실제 구매 기록 21 만 건 (BPIC 2019) 으로
발주부터 지급까지 어느 단계가 가장 오래 걸리고 , 그 지연이 어디에 몰려 있는지 분석

병목 구간

송장 접수 → 지급

보통 43 일 , 10 건 중 1 건은 98 일 이상

집중

포장재 공급사 5 곳

전체 지연의 89%

제안

결제 조건 · 지급 일정 점검

5 개 공급사 우선

문제 정의 › 데이터 · 품질 › 지표 설계 › 검증 › 제안

분석 요약

문제 정의 › 데이터 · 품질 › 지표 설계 › 검증 › 제안

문제

발주부터 지급까지 어느 구간에서 지연이 발생하며 , 어떤 공급사에 집중되는가 ?

지급 지연은 공급사 관계와 자금 계획에 영향을 주지만 , 지연 구간과 원인을 모르면 개선 대상을 정하기 어려움

내 역할

분석 질문 · 지표 · 판단 기준 설계 , 데이터 품질 규칙 수립 , SQL 분석 및 검증

핵심 수치는 두 가지 방법으로 교차 확인 . 판단과 검증 기록은 15 쪽

결과

송장 접수 후 지급까지 보통 43 일 , 10 건 중 1 건은 98 일 이상 . 늦은 지급의 90% 가 포장재 공급사 5 곳

거래량이나 지급 보류로는 설명되지 않음 . 5 개 공급사의 결제 조건과 지급 일정 우선 점검 제안

분석 흐름과 단계별 수행 내용

문제 정의 › 데이터 · 품질 › 지표 설계 › 검증 › 제안

단계	일반적으로 하는 일	이 프로젝트에서 한 일	장
1. 문제 정의	질문 · 범위 · 가설을 정한다	지연 구간과 집중 대상 질문 설정 , 2018 년 before GR 품목 , 가설 5 개	4
2. 데이터 이해 · 품질	구조를 파악하고 결측 · 이상값 · 중복 처리 규칙을 정한다	cases 1:N events · 컬럼 10 개 · 2018 년 이전 날짜 규칙 · 음수 · 중복 처리	5~7
3. 지표 설계	무엇을 어떻게 잴지 정한다	구간 4 개 · 첫 시각 · 중앙값 ·P90 · case_times → lead_times	8
4. 분석 · 검증	가설을 데이터로 확인한다	H1~H5 검증 · 품목 1 건 직접 확인 · 다른 방법으로 재계산	9~12
5. 해석 · 제안	무엇을 바꿀지 , 한계는 무엇인지 쓴다	5 개 공급사부터 점검 · P90 기준 월별 측정 · 한계 · 판단 · 검증 기록 · 재현	13~16

각 장 상단에 현재 단계를 표시 . 저장소 파일 번호와의 대응 : ①② 데이터 · 품질 , ③ 지표 설계 , ④ 검증 , ⑤⑥ 제안 · 재현

상황과 문제 정의

문제 정의 › 데이터 · 품질 › 지표 설계 › 검증 › 제안

배경

- 구매→지급 (P2P) 은 발주 , 입고 , 송장 접수 , 지급으로 이어지는 기본 업무 흐름
- 분석 데이터는 네덜란드 도료 · 코팅 제조사의 2018 년 구매 기록을 익명화한 공개 데이터 (BPIC 2019)
- 지급 지연은 공급사 관계 , 자금 계획 , 조기 결제 할인 활용에 영향
- 실무는 건별 처리 중심이라 전체 흐름에서 막히는 단계를 파악하기 어려움

핵심 질문

발주부터 지급까지 어느 구간에서 지연이 발생하며 , 그 지연은 어떤 공급사와 품목 영역에 집중되는가 ?

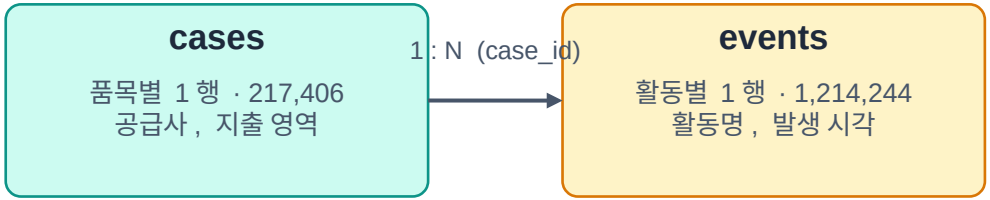
검증할 가설 5 개

- H1 지연은 특정 구간에 몰려 있다
- H2 지연은 소수 공급사 · 영역에 몰려 있다
- H3 거래가 많은 공급사라서 지연도 많다
- H4 지급 보류가 지연의 원인이다
- H5 미지급 품목은 취소 · 변경 · 누락 · 진행 중으로 구분된다

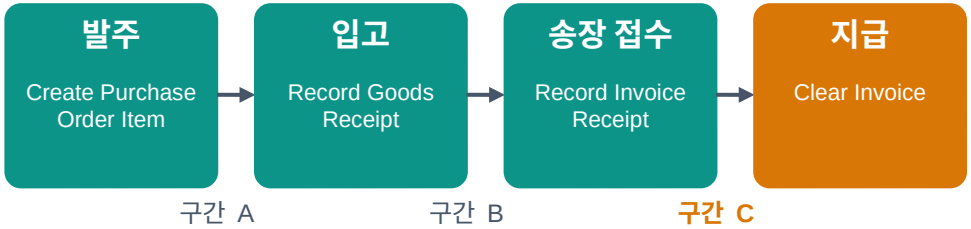
데이터 구성 : 품목 표와 활동 기록 표

출처 · 규모

- BPIC 2019(프로세스 마이닝 공개 대회 데이터) 부분집합을 DuckDB 에 적재
- 품목 217,406 개 , 활동 기록 1,214,244 건 . 기간 2018-01 ~ 2019-01
- 거래 방식은 '3-way match, invoice before GR' 1 종 (원본의 86%) 으로 , 송장이 입고보다 먼저 접수될 수 있음
- 분석 단위는 품목 (case_id), 발주서의 한 줄에 해당



한 품목의 활동 흐름 (28 종 중 분석에 쓴 4 개 시점)



사이사이에 지급 보류 해제 , 변경 · 삭제 · 취소 등의 활동이 기록됨 . 품목당 평균 활동 5.6 건

분석에 사용한 컬럼 10 개

테이블	컬럼	뜻	분석에서 쓴 곳
cases	case_id	품목 번호 = 발주서번호 _ 줄번호 (기본키)	모든 집계의 단위 , 두 테이블 연결 키
cases	purchasing_document / item	발주서 번호 / 발주서 안 줄번호	case_id 의 구성 확인
cases	vendor	공급사 ID (익명화)	지연 집중도 (H2·H3)
cases	spend_area_text	지출 영역 대분류 (Packaging, Sales 등)	지연 집중도 (H2)
cases	item_category	거래 대조 방식 (1 종만 존재)	데이터 범위 · 한계 확인
events	case_id	어느 품목의 활동인지 (외래키)	cases 와 1:N 연결
events	activity	무슨 일인지 (28 종)	4 개 시점 추출 , 마지막 활동 (H5)
events	ts	발생 시각 (UTC 저장)	구간 소요일 계산 , 이상 날짜 점검
events	resource	기록한 사람 (NONE = 기록 없음 17.7%)	담당자 분석에서 제외 근거
events	net_worth_eur	품목 금액 (유로), 활동마다 같은 값 반복	이번 분석에서 미사용

company, name, document_type 등 나머지 컬럼은 미사용 . 컬럼 정의는 BPIC 2019 설명서와 값 분포로 확인

데이터 품질 점검 결과와 처리 규칙

문제 정의 › **데이터 · 품질** › 지표 설계 › 검증 › 제안

발견한 문제	규모	정한 처리	이유
1948·1993·2008 년 같은 불가능한 날짜	197 행 (공급사 송장 발행 191 + 구매요청 6)	품목은 남기고 , 그 날짜만 ' 신뢰 불가 ' 표시 → 소요일 계산에서 제외	품목 193 개 전체 제외를 검토했으나 , 발주→지급 기록이 정상인 품목까지 빠져 날짜만 제외하는 방식으로 결정
송장 접수가 입고보다 먼저 (B 구간 음수)	14,963 품목 (8.7%)	그대로 둠	'invoice before GR' 방식의 정상 흐름
지급이 송장 접수보다 먼저 (C 구간 음수)	9 품목 (0.005%)	C 구간 계산에서 제외	9 건 원본 확인 , 제외 전후 중앙값 동일 (42.99). 원인은 데이터로 확인 불가
같은 (품목 , 활동 , 시각) 중복 행	1,384 묶음 (0.2%)	첫 시각만 쓰므로 소요일에 영향 없음	수량 정보가 없어 중복과 분할 입고 구분 불가 . 횟수 집계 시에만 유의
resource = 'NONE' (기록자 없음)	215,245 행 (17.7%)	담당자 분석에서만 제외	대부분 공급사 측 활동으로 사내 담당자 미기록이 정상

키 점검 : case_id 중복 0 건 , 테이블 간 불일치 0 건 . 소요일 분석 대상은 4 개 시점이 모두 있는 172,241 품목 (79.2%)

측정 기준 : 단계 4 개 , 첫 시각 , 중앙값과 가장 오래 걸린 10%

구간 3 개 + 전체

구간	시작 → 끝
A	발주 → 입고
B	입고 → 송장 접수
C	송장 접수 → 지급
전체	발주 → 지급

- 집계 단위는 품목 . 같은 활동이 반복되면 첫 시각 사용 (마지막 시각은 분할 입고 분석이 별도로 필요해 제외)
- 대표값은 중앙값과 P90. 소수의 장기 지연이 평균을 왜곡하므로 평균 미사용
- 공급사 송장 발행 시각은 이상 날짜 191 건이 몰려 있어 제외

분석용 테이블 1: case_times

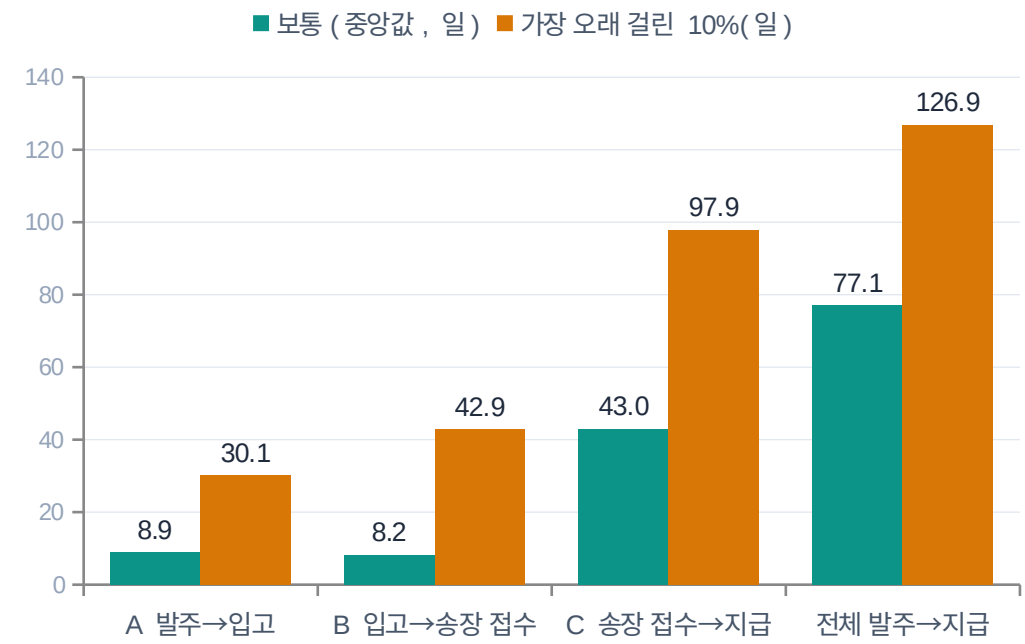
목적 : 활동 121 만 건을 품목별 1 행 (4 개 시점) 으로 변환해 구간 계산이 가능하도록 구성

컬럼	뜻	계산
case_id	품목	GROUP BY
po_ts	첫 발주 시각	MIN(발주 행의 ts)
gr_ts	첫 입고 시각	MIN(입고 행의 ts)
ir_ts	첫 송장 접수 시각	MIN(송장 행의 ts)
pay_ts	첫 지급 시각	MIN(지급 행의 ts)

결과 217,406 행 . 지급 없음 44,594, 송장 접수 없음 18,896, 입고 없음 12,143, 발주 없음 0

H1 검증 : 송장 접수 후 지급까지 43 일 , 가장 긴 단계

문제 정의 › 데이터 · 품질 › **지표 설계** › **검증** › 제안



지급 완료 172,241 품목 기준 . 중앙값은 합산되지 않으므로 A+B+C 와 전체가 다름

C 구간

43 일

송장 접수 후 지급까지 보통 걸리는 기간 . 물건은 9 일 , 송장은 8 일이면 처리되는데 대금 지급은 5 배 넘게 걸림

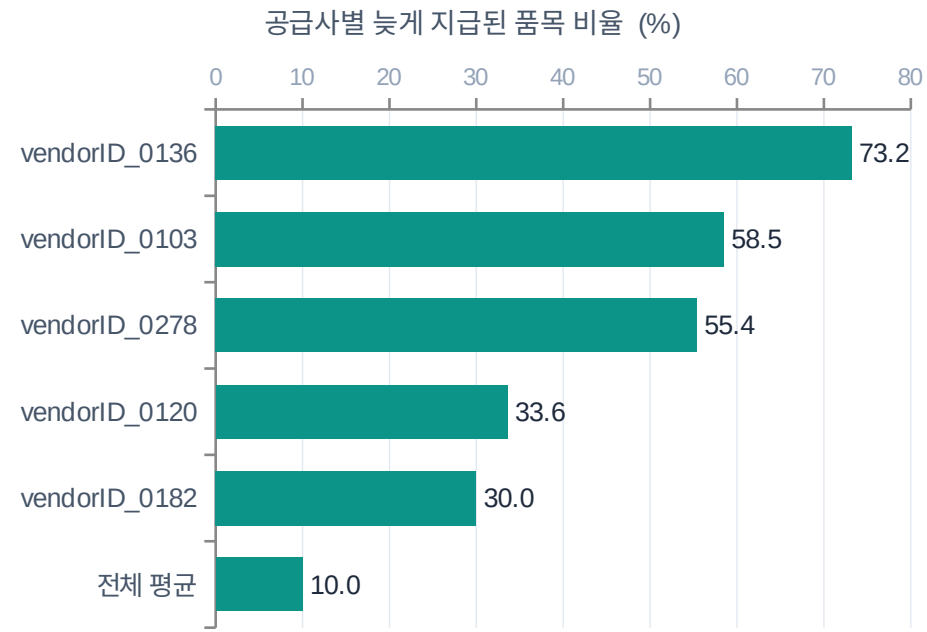
분석용 테이블 2: lead_times

목적 : 4 개 시점 간 차이를 구간별 일수로 계산 . 4 개 시점이 모두 있는 품목 대상

a_ 발주 _ 입고 = (epoch(gr_ts) − epoch(po_ts)) / 86400
b, c, 전체도 같은 방식으로 계산 , C 구간 음수 9 건 제외

H2 검증 : 늦은 지급의 89.7% 는 포장재 공급사 5 곳

문제 정의 › 데이터 · 품질 › 지표 설계 › **검증** › 제안



늦은 지급 기준 : 송장 접수 후 98 일 초과 (가장 오래 걸린 10%) = 17,165 품목

5 개 공급사 지연 15,400 건 , 전체의 89.7%

- 1 위 공급사 0136 이 7,694 건 (44.8%)
- 지출 영역 기준 포장재 (Packaging) 가 지연의 93.4%(지연 비율 21.9%, 그 외 영역 2.5% 이하)
- 공급사 × 영역 교차 시 5 개 공급사의 지연은 대부분 Packaging

판단 기준

- 범위 : 지연 누적 90% 를 포함하는 상위 10 개 공급사 (92.9%)
- 우선 대상 : 지연 비율 30% 이상 (전체 평균 10% 의 3 배)
- 사용 테이블 : lead_times 와 cases 결합 (vendor, spend_area_text)

H3·H4 검증 : 거래량 · 지급 보류로는 설명 불가

문제 정의 › 데이터 · 품질 › 지표 설계 › **검증** › 제안

H3 거래가 많아서 지연도 많다 : 아님

공급사	전체 품목	지연 품목	지연 비율
vendorID_0136	10,518	7,694	73.2%
vendorID_0120	10,411	3,493	33.6%

품목 수가 비슷한 두 공급사의 지연 비율이 2 배 이상 차이

H4 지급 보류가 원인이다 : 일부만 맞음

0136 품목	보류 해제 기록 있음
지연 7,694	4,455 (57.9%)
지연 아님 2,824	1,201 (42.5%)

차이 15%p 로 보류만으로는 설명 부족 . 보류 설정 기록은 52 건뿐이라 해제 기록으로 간접 확인

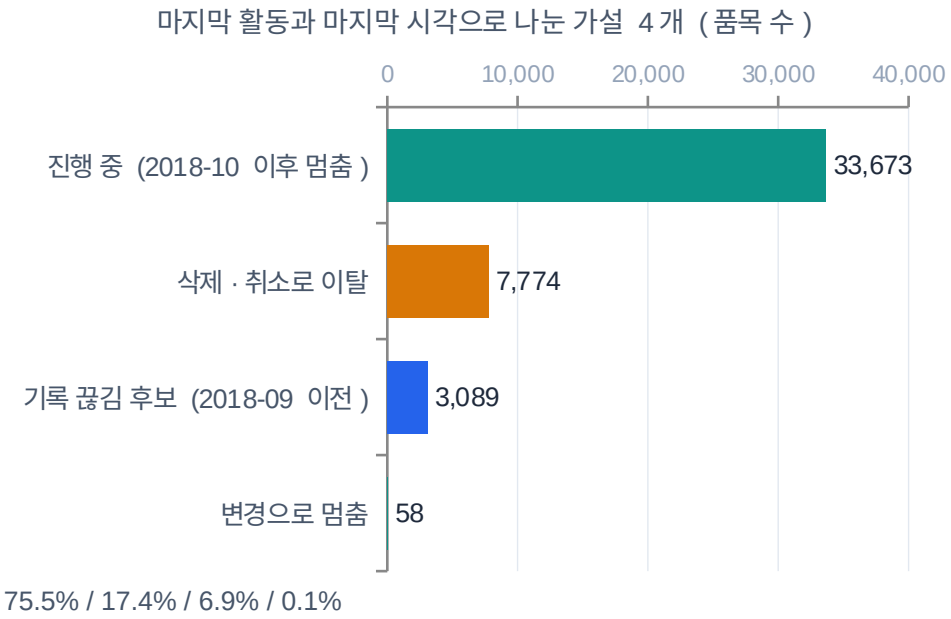
사례 품목 원본 확인



품목 4508044951_00020(0136, C 구간 119.9 일): 보류 해제 다음 날부터 4 개월간 활동 없이 대기 . 지연은 보류 처리가 아니라 해제 이후 지급 대기에서 발생

H5 검증 : 미지급 건의 75.5% 는 진행 중

문제 정의 › 데이터 · 품질 › 지표 설계 › **검증** › 제안



75.5% / 17.4% / 6.9% / 0.1%

57.8% 가 송장 접수 후 지급 대기

마지막 활동이 송장 접수 또는 보류 해제인 25,778 품목 . 지급 완료 품목과 같은 C 구간에서 정체

분류 기준

- 품목별 마지막 활동으로 삭제 · 취소 · 변경 먼저 분류
- 나머지는 마지막 시각 기준 . 데이터 종료 시점 (2019-01) 에서 P90(97.9 일) 이내면 진행 중으로 분류해 지연 기준과 통일
- 기준을 2018-11 로 바꿔도 83% 로 결론 동일

결론 : 공급사 5 곳 우선 점검으로 늦은 지급의 90% 관리 가능

문제 정의 › 데이터 · 품질 › 지표 설계 › 검증 › **제안**

처음 질문

어느 구간에서 지연이 발생하며 , 어떤 공급사에 집중되는가 ?

확인한 문제

송장 접수 후 지급까지 보통 43 일로 가장 긴 단계이며 , 늦은 지급의 89.7% 가 포장재 공급사 5 곳에 집중 . 거래량이나 보류로는 설명되지 않고 , 미지급 2.6 만 건도 같은 단계에서 대기

제안

전체 공급사를 다 볼 필요 없이 , 지급 담당 부서가 포장재 공급사 5 곳의 결제 조건과 지급 일정부터 확인 . 늦은 지급의 89.7% 가 대상

측정 체계

' 송장 접수 후 98 일 초과 ' 를 지연 기준으로 고정하고 공급사별 지연 비율을 매달 같은 방식으로 확인 . 이번 분석 SQL 을 월별 점검에 그대로 사용

한계와 다음 질문

문제 정의 › 데이터 · 품질 › 지표 설계 › 검증 › 제안

한계

- 거래 방식 1 종 (invoice before GR, 원본의 86%) 만 포함되어 방식 간 비교 불가
- 결제 조건 , 지급 일정 정보가 없어 지연 원인이 공급사 요인인지 지급 절차 요인인지 구분 불가
- 구매 회사 (company) 별 차이 미분석
- 지급 보류는 해제 기록 (54,458 건) 으로만 간접 확인 , 설정 기록은 52 건
- 미지급 품목의 진행 중 판단 기준 (2018-10) 은 P90 을 적용한 가정

다음 질문

- 송장 선접수 여부에 따른 지급 소요일 차이 검정
- 미지급 상위 공급사 (0104, 0106) 의 지연 여부 추가 확인
- 구매 회사별 지연 비율 비교로 절차 요인 확인
- 월별 지연 비율 추이로 측정 체계 적용 가능성 확인

주요 판단과 검증 기록

문제 정의 › 데이터 · 품질 › 지표 설계 › 검증 › **제안**

단계	검토한 대안	정한 것	검증
품질 규칙	2018 년 이전 날짜가 있는 품목 193 개 통째 제외	품목은 남기고 날짜만 ' 신뢰 불가 ' 표시 → 소요일 계산에서 제외	사례 품목의 발주→지급 기록이 정상 . 전체 제외 시 송장 선접수 품목이 편향적으로 빠짐
지표 정의	마지막 시각 기준 , 평균	첫 시각 기준 , 중앙값 ·P90	미지급 44,594 건을 서로 다른 두 쿼리로 산출해 일치 확인
집중도	지연 건수만으로 순위	지연 건수 + 지연 비율 (전체 품목 대비) 함께 , 우선 대상 기준은 평균의 3 배	1 위 공급사 사례 품목의 원본 기록과 계산된 소요일 대조
미지급 분류	경계 2018-11 (데이터 끝 2~3 개월)	경계 2018-10 (데이터 끝에서 P90 97.9 일 안) → 지연 기준과 같은 숫자	기준을 11 월로 바꿔도 83% 로 결론 유지
C 음수 9 건	그대로 두기	C 계산에서 제외	제외 전후 중앙값 동일 (42.99)

모든 수치는 저장소에서 명령 한 줄로 재현 가능 (16 쪽). 단계별 결정 근거는 notes/ 폴더에 기록

재현 방법

모든 수치는 저장소에서 명령 한 줄로 재현 가능

```
.venv/bin/python src/run_my_sql.py     # my_sql/01~06 순서대로 실행, 쿼리별 결과 출력
```

my_sql/01~02
데이터 이해 · 품질 점검

my_sql/03~04
지표 정의 · 구간 소요일 · 음수 검증

my_sql/05~06
지연 집중도 · 미지급 가설 구분

notes/my_01~04
단계별 질문, 결정, 결과, 한계 기록

src/run_my_sql.py
읽기 전용 연결로 임시 테이블을 유지하며 전체 실행

data/p2p.duckdb
BPIC 2019 부분집합 적재본 (src/load.py 로 생성)

GitHub: (공개 후 링크) · 데이터 출처 : BPIC 2019, Zenodo record 17295283 (3-way match, invoice before GR 부분집합)